LAPORAN PRAKTIKUM
DATA MINING

Materi:
Seleksi Data

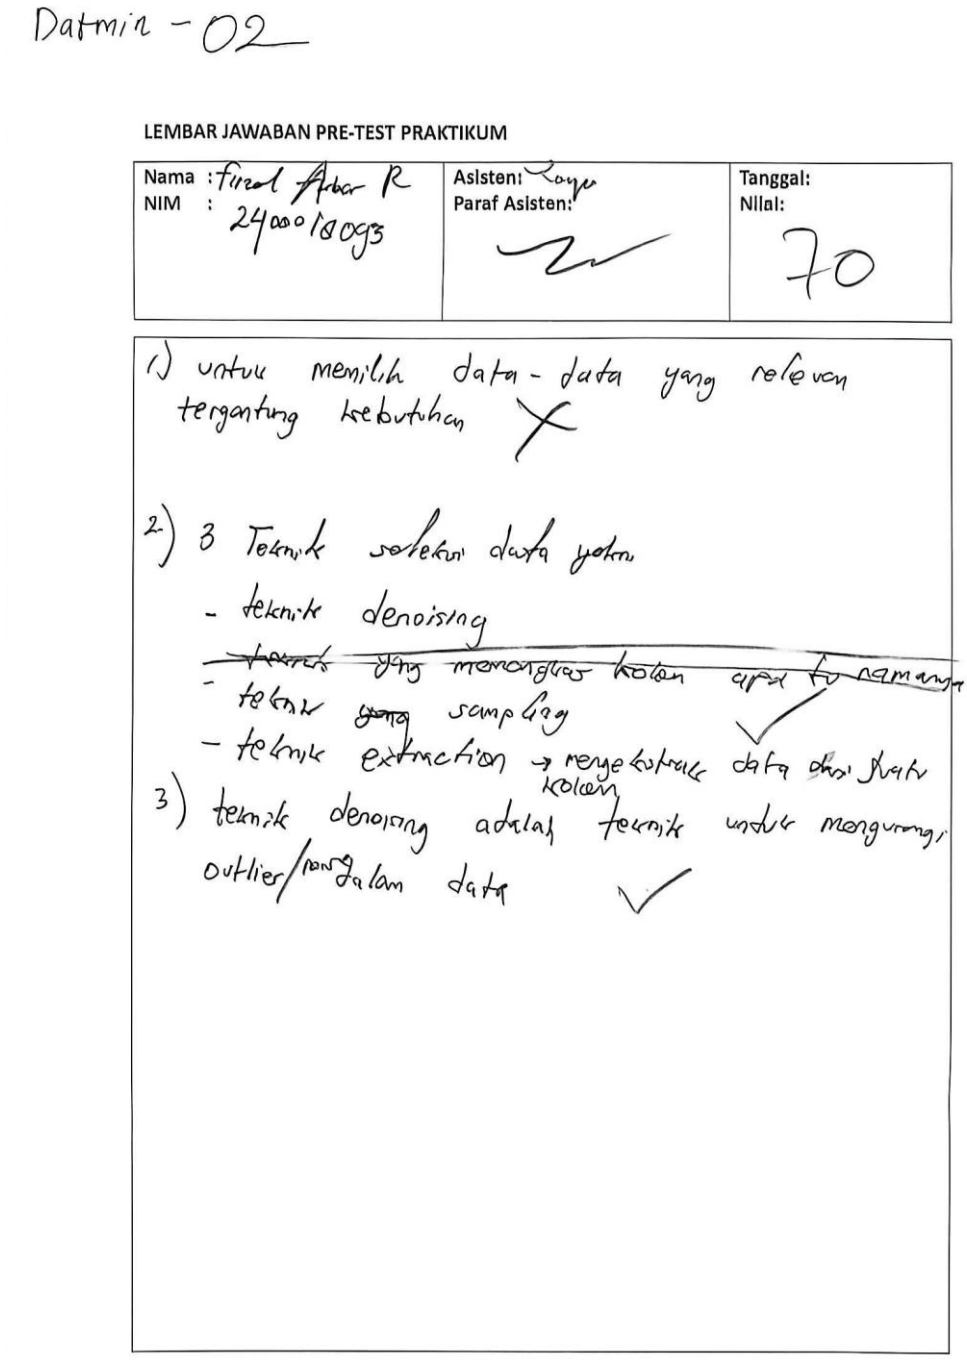
Disusun Oleh:
Firzal Akbar Ramadhan
2400018093

PROGRAM STUDI S1 INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
UNIVERSITAS AHMAD DAHLAN

2026

Pre Test

Bagian ini memuat hasil pengerjaan lembar jawaban Pre-Test pada praktikum pertemuan ini:



Datmin - 02

LEMBAR JAWABAN PRE-TEST PRAKTIKUM

Nama : Fiqal Akbar R NIM : 24000180093	Asisten: Rayyi Paraf Asisten:	Tanggal: Nilai: 70

1) untuk memilih data - data yang relevan tergantung kebutuhan ✗

2) 3 Teknik seleksi data yaitu
- teknik denoising
- ~~teknik yang mengatasi kolom apa ke samanya~~
- teknik yang sampling ✓
- teknik extraction → mengekstraksi data dari suatu kolom

3) teknik denoising adalah teknik untuk mengurangi outlier/pengalam data ✓

CS Scanned with CamScanner

Gambar 2.1 Lembar Jawaban Pre-Test Praktikum Pertemuan 2

Hasil Praktikum

Praktikum pertemuan 2 berfokus pada tahapan seleksi data (data selection) dalam proses penambangan data. Tujuannya adalah memilih atribut yang relevan dengan tujuan analisis serta mereduksi derau (noise) dan redundansi data agar efisiensi komputasi meningkat.

2.1 Pembacaan Dataset Alumni dan Eksplorasi Awal

Proses dimulai dengan membaca file dataset 'data_alumni.csv' menggunakan pustaka Pandas. Dataset memuat berbagai informasi alumni seperti riwayat akademik, waktu tunggu kerja, dan bidang pekerjaan. Fungsi df.head() dijalankan untuk memeriksa sampel baris teratas.

	No	Nim	Nama	Tempat & tanggal lahir	Fakultas/Ketrampilan	Alamat	Tahun Masuk	Tahun Lulus	Status Pekerjaan	Lama Masa Tunggu (bulan)	Pe bek
0	1	9018263	Puguh Drajat E.P	Purworejo, 4 November 1989	FTI / Teknik Iformatika	Tangerang Rt. 01/ 0	2009	2016	NaN	2.4	1475
1	2	12022030	Arsyad Cahya Subrata	Bantul, 21 juni 1994	FTI / Teknik Elektro	Karangpule Rt.01 , Tirtonirmolo , Kasihan Bantul	2012	2016	NaN	NaN	
2	3	12020021	Yesi Novela	Tempilang, 1 januari 1995	FTI	NaN	2012	2016	Mahasiswa	2.4	1475
3	4	9018269	Pandu Herwijaya	Lampung, 19 Desember 1990	FTI/ Teknik Infomatika	Tamantirto, Kasihan ,Bantul	2009	2016	NaN	2.4	1475
			Anjar	Gunungkidul,		Umbulharjo					

Gambar 2.2 Pemuatan Dataset Alumni Menggunakan Pandas

2.2 Teknik Seleksi Fitur yang Relevan

Pada tahap ini dilakukan pemilahan kolom-kolom penting yang berpengaruh langsung terhadap analisis kelulusan dan karir alumni. Kolom administratif yang tidak memiliki korelasi analitis dipisahkan untuk mereduksi dimensi data.

2.3 Penanganan Data Noise dan Redundansi (Denoising)

Pembersihan noise dilakukan dengan memverifikasi konsistensi nilai kategorikal dan memfilter anomali nilai. Teknik denoising memastikan bahwa data yang masuk ke tahap pemodelan memiliki kualitas representasi yang tinggi.

Ulasan Praktikum

Seleksi data merupakan tahapan krusial dalam KDD (Knowledge Discovery in Databases). Dengan mengeliminasi fitur-fitur yang tidak relevan atau mengandung banyak derau, model machine learning dapat belajar lebih cepat, menghindari overfitting, serta menghasilkan akurasi prediksi yang lebih reliabel.

Post Test

Latihan post-test diambil langsung dari notebook 'Copy of REKAYASA DAN PENAMBANGAN DATA PERTEMUAN 2.ipynb' menggunakan dataset 'siswa.csv':

1. Dimensi Awal Dataset dan Seleksi Subset Data Siswa

Dimensi awal dataset 'siswa.csv' diperiksa menggunakan da.shape yang menghasilkan (29, 18). Kemudian diambil subset data yang hanya memuat kolom Nama, jen kel, Tgl Lahir, Thn msk, dan lulus. Lima baris pertama berhasil ditampilkan dengan rapi.

```
da = pd.read_csv('siswa.csv')
print('Row x Column: ', da.shape)
da2 = da.loc[:, ['Nama', 'jen kel', 'Tgl Lahir', 'Thn msk',
'lulus']].head()
da2.head()
```

Kode 2.1 Pengecekan Dimensi Awal dan Ekstraksi Subset Kolom

2. Pembuatan Fitur Baru 'Masa Studi'

Fitur baru 'Masa Studi' dibuat dengan menghitung selisih tahun kelulusan ('lulus') terhadap tahun masuk ('Thn msk'). Lima baris pertama data siswa ditampilkan bersama fitur Masa Studi yang telah terbentuk (misal: Ani Yuanita, Thn msk 2000, lulus 2007 -> Masa Studi 7.0 tahun).

```
da3 = da.copy()
for index, row in da3.iterrows():
    da3.loc[index, 'Masa Studi'] = int(row['lulus']) - int(row['Thn
msk'])

da3.loc[:, ['Nama', 'Thn msk', 'lulus', 'Masa Studi']].head()
```

Kode 2.2 Perhitungan Fitur Masa Studi Siswa

3. Pembuatan Fitur Baru 'Usia Lulus'

Fitur 'Usia Lulus' dibentuk dengan menjumlahkan 'usia msk' dan 'Masa Studi'. Lima baris terakhir data ditampilkan (misal: Agus Dwi Saputra, usia msk 7, Masa Studi 7.0 -> Usia Lulus 14.0 tahun).

```
da4 = da3.copy()
for index, row in da4.iterrows():
    da4.loc[index, 'Usia Lulus'] = row['usia msk'] + row['Masa
Studi']

da4.loc[:, ['Nama', 'usia msk', 'Masa Studi', 'Usia Lulus']].tail()
```

Kode 2.3 Pembuatan Fitur Usia Lulus

4. Pengecekan Missing Value dan Ringkasan Proses Ekstraksi Fitur

Pengecekan missing value pada fitur hasil ekstraksi ('Masa Studi' dan 'Usia Lulus') menunjukkan nilai 0 (bersih tanpa noise). Ringkasan proses seleksi data:

- Jumlah baris awal: 29 baris
- Jumlah kolom awal: 17 kolom
- Jumlah kolom setelah ekstraksi: 20 kolom

```
print('--- Cek Missing Value pada Fitur Hasil Ekstraksi ---')
print(da4[['Masa Studi', 'Usia Lulus']].isnull().sum())

ringkasan = {
    'Jumlah baris awal': len(da4),
    'Jumlah kolom awal': len(da4.columns) - 3,
    'Jumlah kolom setelah ekstraksi': len(da4.columns)
}
print('\n--- Ringkasan Proses Seleksi Data ---')
for k, v in ringkasan.items():
    print(f'{k:32s}: {v}')
```

Kode 2.4 Verifikasi Integritas Data dan Ringkasan Ekstraksi