LAPORAN PRAKTIKUM
DEEP LEARNING

Materi:
Tuning Hyperparameter

Disusun Oleh:
Firzal Akbar Ramadhan
2400018093

PROGRAM STUDI S1 INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
UNIVERSITAS AHMAD DAHLAN
2026

Pre Test

Bagian ini memuat hasil pengerjaan lembar jawaban Pre-Test pada praktikum pertemuan ini:

DL-02

LEMBAR JAWABAN PRE-TEST PRAKTIKUM

Nama : firzal Akbar R NIM : 2400018093	Asisten: Paraf Asisten: 	Tanggal: Nilai: 10

1.) Hyperparameter adalah parameter konfigurasi yang nilainya ditentukan sebelum proses pelatihan (training) dimulai.
- Learning rate : seberapa besar ukuran langkah pembaruan bobot pada setiap iterasi optimasi
- number layers (Hidden layers). Jumlah lapisan tersembunyi dan jumlah neuron dalam setiap lapisan yang menentukan kapasitas model untuk pola kompleks.
- Batch size : jumlah sampel data yang diproses sebelum model memperbarui parameter internal
- Epochs : Jumlah total siklus pelatihan dimana seluruh dataset melewati jaringan saraf.
- Activation function : fungsi matematika (ReLU, Sigmoid) yang menentukan non-linearitas output suatu neuron
- Optimizer : Algoritma (seperti Adam, SGD, atau RMSprop) yang mengatur cara bobot model diperbarui berdasarkan fungsi loss

2) 1.) Membuat fungsi model : Mendefinisikan fungsi Python yang mengembalikan model Keras yang dikompilasi.
2) Memilih Tuner : Pilih algoritma pencarian (tuner) yang diinginkan seperti RandomSearch, Hyperband, atau Bayesian Optimization
3). Melakukan pencarian (search) : Panggil metode .search() pada objek tuner dengan memberikan data latih dan data validasi anda.
4.) Mendapatkan model terbaik : Ambil model dengan performa optimal menggunakan metode .get_best_models()

CS Scanned with CamScanner

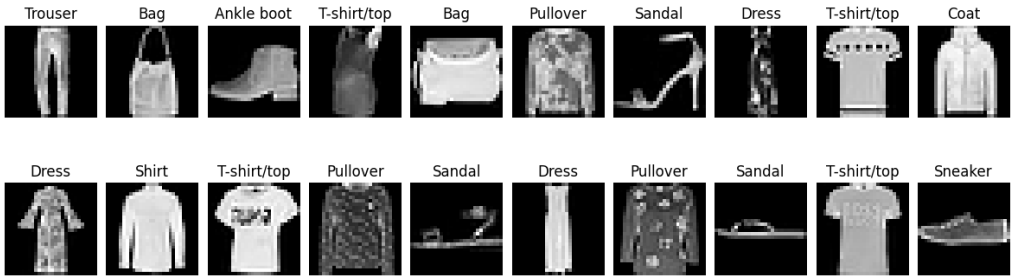
Gambar 2.1 Lembar Jawaban Pre-Test Praktikum Pertemuan 2

Hasil Praktikum

Praktikum pertemuan 2 membahas optimasi performa model melalui penyesuaian Hyperparameter secara sistematis menggunakan Keras Tuner.

2.1 Teori Hyperparameter dan Dataset Fashion MNIST

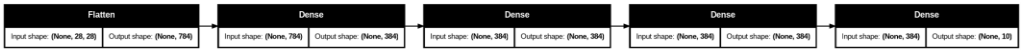
Hyperparameter dibedakan menjadi arsitektural (jumlah hidden layer, jumlah neuron, fungsi aktivasi) dan algoritmik (learning rate, optimizer, batch size, epoch). Dataset Fashion MNIST dimuat dan diperiksa sampel kategorinya.



Gambar 2.2 Sampel Citra Dataset Fashion MNIST (2x10 Grid)

2.2 Perancangan Model Builder dan Random Search Tuner

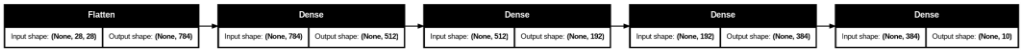
Fungsi pembangunan model didefinisikan dengan parameter tuning. Algoritma RandomSearch dijalankan dan arsitektur model terbaik divisualisasikan menggunakan plot_model Keras.



Gambar 2.3 Visualisasi Arsitektur Model Terbaik dari Tuner Random Search

2.3 Optimasi Adaptif dengan Hyperband Tuner

Algoritma Hyperband dijalankan untuk mencari konfigurasi hyperparameter terbaik secara adaptif dengan early stopping.



Gambar 2.4 Visualisasi Arsitektur Model Terbaik dari Tuner Hyperband

Ulasan Praktikum

Keras Tuner sangat menghemat waktu eksplorasi parameter dibanding penyesuaian manual. Pemilihan rentang nilai pencarian (search space) yang rasional menjadi kunci sukses efisiensi komputasi tuning.

Post Test

Latihan post-test diambil langsung dari notebook '2400018093 Praktikum 2- Tuning Hyperparameter post test.ipynb' pada dataset Fashion MNIST:

1. Perancangan Model Post-Test (3 Hidden Layers) dengan Keras Tuner

Model dirancang ulang dengan menambahkan 2 hidden layer baru (total 3 hidden layer). Rentang pencarian jumlah neuron (units_1, units_2, units_3) disetel antara 64 hingga 512 dengan interval step 64. Fungsi aktivasi dan learning rate Adam optimizer diintegrasikan ke dalam hyperparameter search space.

```
 1  def build_model(hp):
 2      ch_unit1 = hp.Int('units_1', min_value=64, max_value=512,
step=64)
 3      ch_unit2 = hp.Int('units_2', min_value=64, max_value=512,
step=64)
 4      ch_unit3 = hp.Int('units_3', min_value=64, max_value=512,
step=64)
 5      ch_activation = hp.Choice('activation', values=['relu', 'tanh',
'sigmoid'])
 6      ch_learning_rate = hp.Choice('learning_rate', values=[1e-2, 1e-
3, 1e-4])
 7
 8      model = Sequential([
 9          Flatten(input_shape=(28, 28)),
10          Dense(units=ch_unit1, activation=ch_activation),
11          Dense(units=ch_unit2, activation=ch_activation),
12          Dense(units=ch_unit3, activation=ch_activation),
13          Dense(10, activation='softmax')
14      ])
15
16      model.compile(
17
optimizer=tf.keras.optimizers.Adam(learning_rate=ch_learning_rate),
18          loss='sparse_categorical_crossentropy',
19          metrics=['accuracy'])
20      return model
```

Kode 2.1 Pembangunan Model Builder 3 Hidden Layer untuk Post-Test

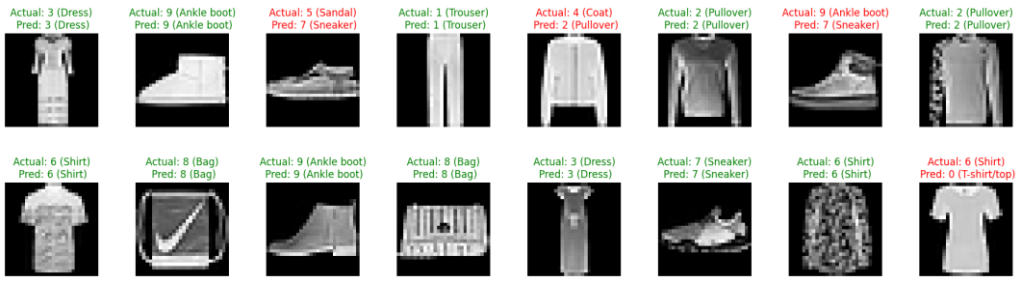
2. Konfigurasi Inisialisasi Tuner: RandomSearch vs Hyperband

Kedua tuner diinisialisasi dengan direktori penyimpanan hasil terpisah:
- RandomSearch: directory='random_search_post_test', max_trials=4, executions_per_trial=2
- Hyperband: directory='hyperband_post_test', max_epochs=5, executions_per_trial=2

```
 1  tuner_random = RandomSearch(
 2      build_model, objective='val_accuracy', max_trials=4,
 3      executions_per_trial=2, directory=join(root_path,
'random_search_post_test'),
 4      project_name='mnist_random'
 5  )
```

```
 6
 7  tuner_hyperband = Hyperband(
 8      build_model, max_epochs=5, objective='val_accuracy',
 9      executions_per_trial=2, directory=join(root_path,
'hyperband_post_test'),
10      project_name='mnist_hyperband'
11  )
```

Kode 2.2 Inisialisasi Tuner Random Search dan Hyperband Post-Test



Gambar 2.5 Hasil Prediksi Citra Uji Model Random Search (2x8 Grid)

3. Kesimpulan Analisis Hasil Eksperimen Post-Test: Hyperband vs Random Search

Berdasarkan hasil pengujian pada dataset Fashion MNIST:

a. Efisiensi Waktu & Penggunaan Resource:
- Random Search menguji seluruh kombinasi secara seragam tanpa eliminasi dini, menghabiskan waktu sekitar 3 menit 1 detik.
- Hyperband menggunakan alokasi adaptif dan early stopping berbasis bracket, memangkas trial berkinerja buruk di epoch awal sehingga komputasi terfokus pada konfigurasi potensial.

b. Performa Akurasi pada Test Set:
- Validation Accuracy (Random Search): 86.27%
- Validation Accuracy (Hyperband): 86.88% (Akurasi validasi terbaik mencapai 87.62%)

c. Parameter Arsitektur Terbaik:
- Hyperband: [512, 192, 384] neuron, aktivasi 'relu', learning rate 0.000816
- Random Search: [384, 384, 384] neuron, aktivasi 'relu', learning rate 0.001419

Kesimpulan Akhir: Hyperband terbukti jauh lebih unggul dan efisien dibanding Random Search konvensional dalam menemukan konfigurasi optimal pada search space yang luas.



Gambar 2.6 Hasil Prediksi Citra Uji Model Hyperband (2x8 Grid)