LAPORAN PRAKTIKUM
PEMROSESAN BAHASA ALAMI

Materi:
Preprocessing (Filtering dan Tokenization)

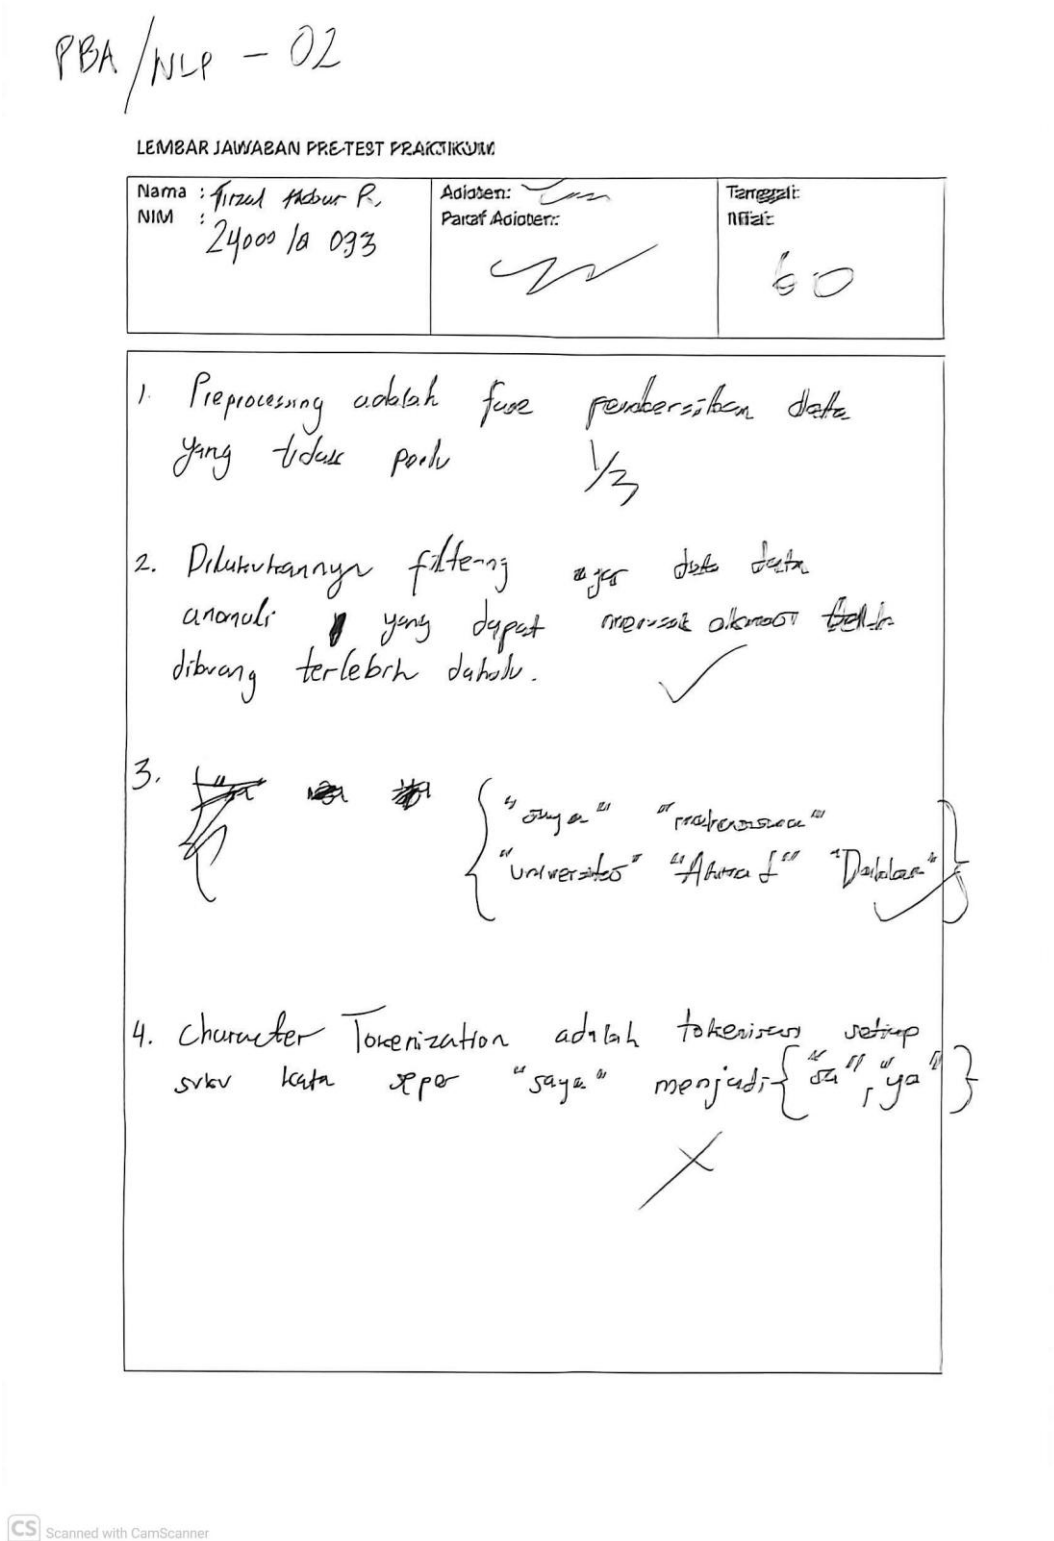
Disusun Oleh:
Firzal Akbar Ramadhan
2400018093

PROGRAM STUDI S1 INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
UNIVERSITAS AHMAD DAHLAN

2026

Pre Test

Bagian ini memuat hasil pengerjaan lembar jawaban Pre-Test pada praktikum pertemuan ini:



PBA / NLP - 02

LEMBAR JAWABAN PRE-TEST PRAKTIKUM

Nama : Firzal Akbar R. NIM : 24000 la 033	Asisten: Paraf Asisten:	Tanggal: Nilai: 60

1. Preprocessing adalah fase pembersihan data yang tidak perlu 1/3
2. Pentingnya filtering agar data data anomali yang dapat merusak akurasi tidak dibuang terlebih dahulu. ✓
3. ~~[illegible]~~ { "saya" "mahasiswa" "universitas" "Akbar" "Dalolae" }
4. Character Tokenization adalah tokenisasi setiap suku kata seperti "saya" menjadi { "sa" "ya" } ✗

CS Scanned with CamScanner

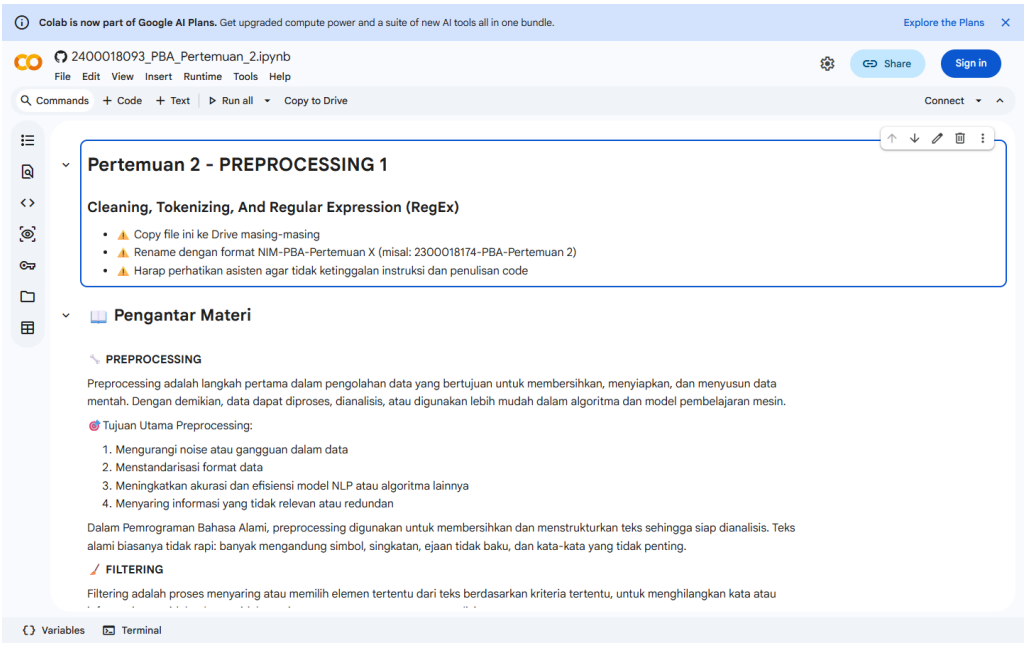
Gambar 2.1 Lembar Jawaban Pre-Test Praktikum Pertemuan 2

Hasil Praktikum

Praktikum pertemuan 2 membahas alur Pembersihan Teks (Text Preprocessing), mencakup case folding, filtering karakter noise/tanda baca, dan tokenisasi kata serta karakter.

2.1 Lingkungan Kerja Preprocessing pada Google Colab

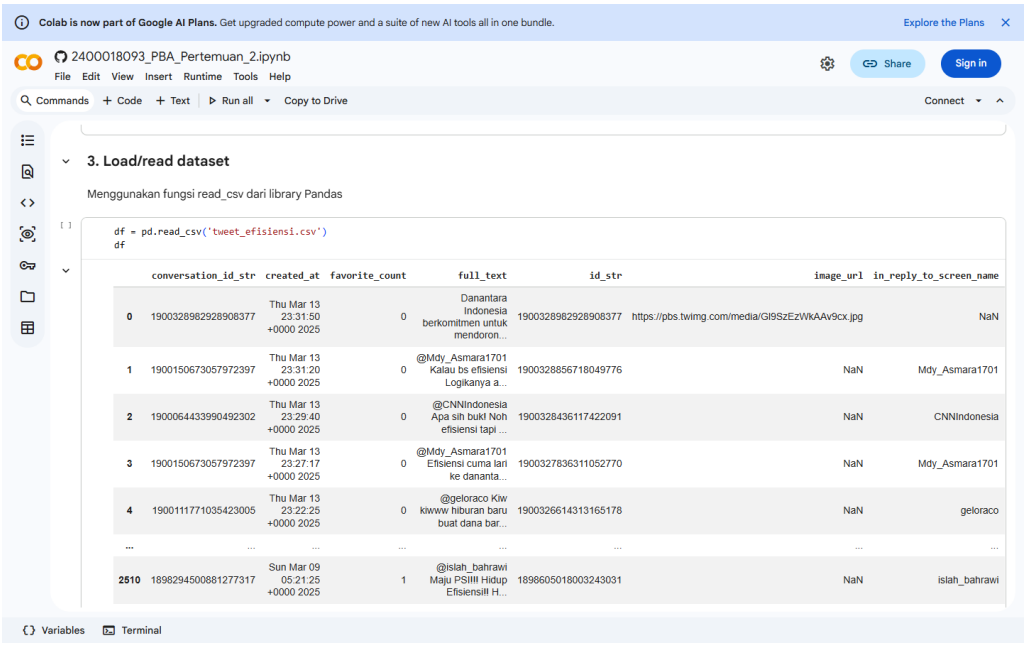
Notebook Colab disiapkan dengan memuat fungsi pembersih teks bahasa alami dan korpus kalimat pengujian.



Gambar 2.2 Tampilan Header Notebook Preprocessing NLP

2.2 Case Folding dan Filtering Pola Karakter

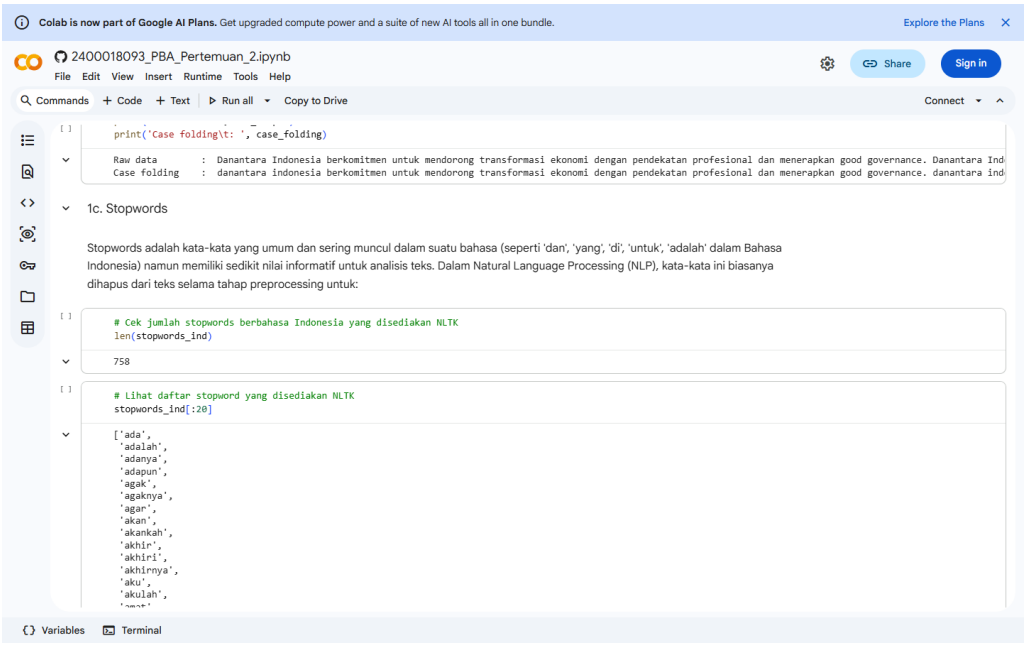
Teks diubah menjadi huruf kecil (lowercase) dan disaring menggunakan regex untuk menghilangkan URL, mention, dan tanda baca.



Gambar 2.3 Kode Implementasi Filtering dan Pembersihan Teks

2.3 Tokenisasi Kata (Word Tokenization)

Kalimat yang telah bersih dipecah menjadi unit-unit kata (token) individual untuk dianalisis frekuensinya.



Gambar 2.4 Hasil Tokenisasi Teks Menjadi Vektor Token

Ulasan Praktikum

Preprocessing merupakan tahapan paling krusial dalam NLP karena teks mentah mengandung banyak noise (simbol, emoji, variasi huruf kapital). Tanpa filtering dan tokenisasi yang tepat, model NLP akan menghasilkan representasi fitur yang terdistorsi.

Post Test

Latihan post-test diambil langsung dari notebook '2400018093_PBA_Pertemuan_2.ipynb' menggunakan alur pemrosesan data tweet bertema 'danantara':

1. Ekstraksi Subset Data dan Filtering Kata Kunci 'Danantara'

Data dari indeks 0 hingga 200 diambil menggunakan df.head(201) dan disimpan ke variabel 'df_baru'. Selanjutnya, dilakukan pemfilteran teks tweet yang mengandung substring kata 'danantara' secara case-insensitive dan disimpan ke dalam DataFrame 'filter_df_baru'.

```
df_baru = df.head(201)
filter_df_baru = df_baru[df_baru['full_text'].str.contains('danantara', case=False, na=False)]
print('Jumlah tweet memuat danantara:', len(filter_df_baru))
```

Kode 2.1 Ekstraksi Subset dan Filter Kata Kunci Danantara

2. Penerapan Pipeline Preprocessing (Cleaning, Case Folding, dan Stopwords)

Fungsi text_preprocessing_process() diterapkan pada kolom 'full_text' untuk membersihkan URL, mention (@username), tanda baca, mengubah seluruh teks ke huruf kecil (case folding), serta mengeliminasi kata-kata umum (stopwords) Bahasa Indonesia. Hasil pembersihan disimpan ke dalam kolom baru 'cleaned_text'.

```
filter_df_baru['cleaned_text'] = filter_df_baru['full_text'].apply(text_preprocessing_process)
filter_df_baru[['full_text', 'cleaned_text']].head()
```

Kode 2.2 Eksekusi Cleaning dan Stopwords Removal

3. Tokenisasi Kata dan Analisis Frekuensi Token

Teks bersih dipecah menjadi vektor token kata menggunakan fungsi tokenize_text(). Kemudian kemunculan setiap token dihitung menggunakan metode explode() dan value_counts(). Sepuluh token teratas dengan frekuensi kemunculan tertinggi:

- danantara: 7 kemunculan
- efisiensi: 7 kemunculan
- indonesia: 3 kemunculan
- ekonomi: 2 kemunculan
- berkomitmen: 2 kemunculan
- ga: 2 kemunculan
- kebijakan: 2 kemunculan
- anggaran: 2 kemunculan
- dana: 2 kemunculan
- menerapkan: 1 kemunculan

```
filter_df_baru['tokenized_text'] = filter_df_baru['cleaned_text'].apply(tokenize_text)
cek_freq = filter_df_baru['tokenized_text'].explode().value_counts()
```

```
3  print(cek_freq.head(10))
```

Kode 2.3 Tokenisasi Kata dan Perhitungan Frekuensi Token