LAPORAN PRAKTIKUM
PEMROSESAN BAHASA ALAMI

Materi:

Preprocessing (Stemming dan Regular Expression)

Disusun Oleh:

Firzal Akbar Ramadhan

2400018093

PROGRAM STUDI S1 INFORMATIKA

FAKULTAS TEKNOLOGI INDUSTRI

UNIVERSITAS AHMAD DAHLAN

2026

Pre Test

Bagian ini memuat hasil pengerjaan lembar jawaban Pre-Test pada praktikum pertemuan ini:

LEMBAR JAWABAN PRE-TEST DAN POST-TEST PRAKTIKUM

Nama : Fiezal Akbar Ramadhan NIM : 2400018093	Asisten: Paraf Asisten:	Tanggal: Nilai:

1) Stemming adalah proses penghilangan prefix dan suffix pada kata berimbuhan. Tujuannya adalah untuk mengurangi noise saat analisis teks

2) Algoritma populer adalah Porter
Algoritma yang digunakan untuk bahasa Indonesia yaitu Sastrawi

3) re.sub(r'\d+', '', text)

~~#~~ ~~menghapus semua jenis karakter pada string~~

4) menghapus spasi berlebihan

Scanned with CamScanner

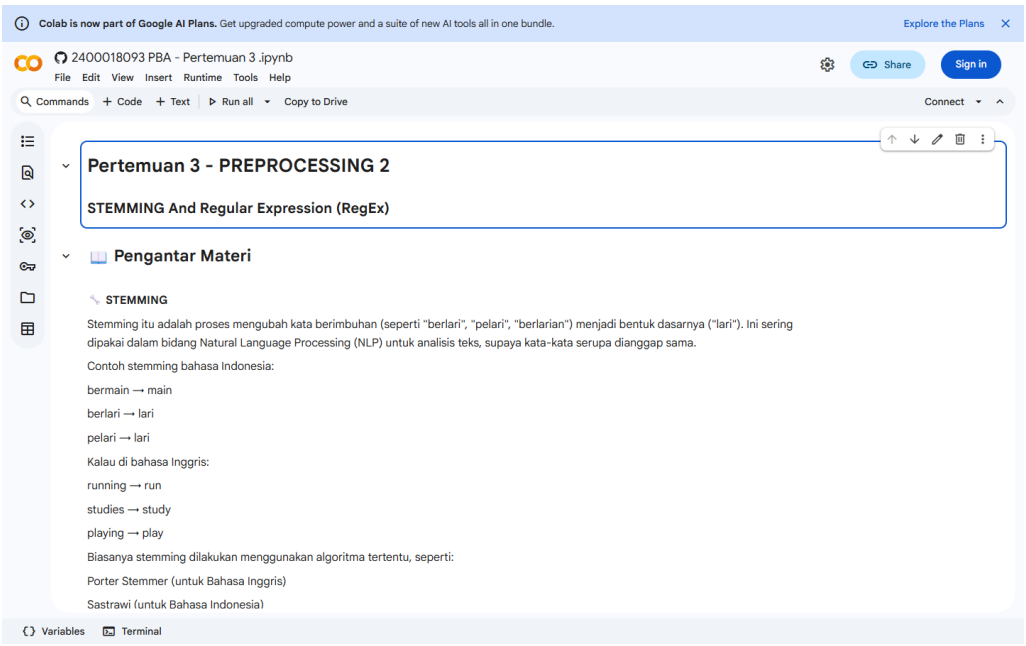
Gambar 3.1 Lembar Jawaban Pre-Test Praktikum Pertemuan 3

Hasil Praktikum

Praktikum pertemuan 3 membahas reduksi kata berimbuhan menjadi kata dasar (Stemming) menggunakan algoritma Sastrawi untuk Bahasa Indonesia dan manipulasi pola teks menggunakan Regular Expression (Regex).

3.1 Pustaka Sastrawi Stemmer pada Google Colab

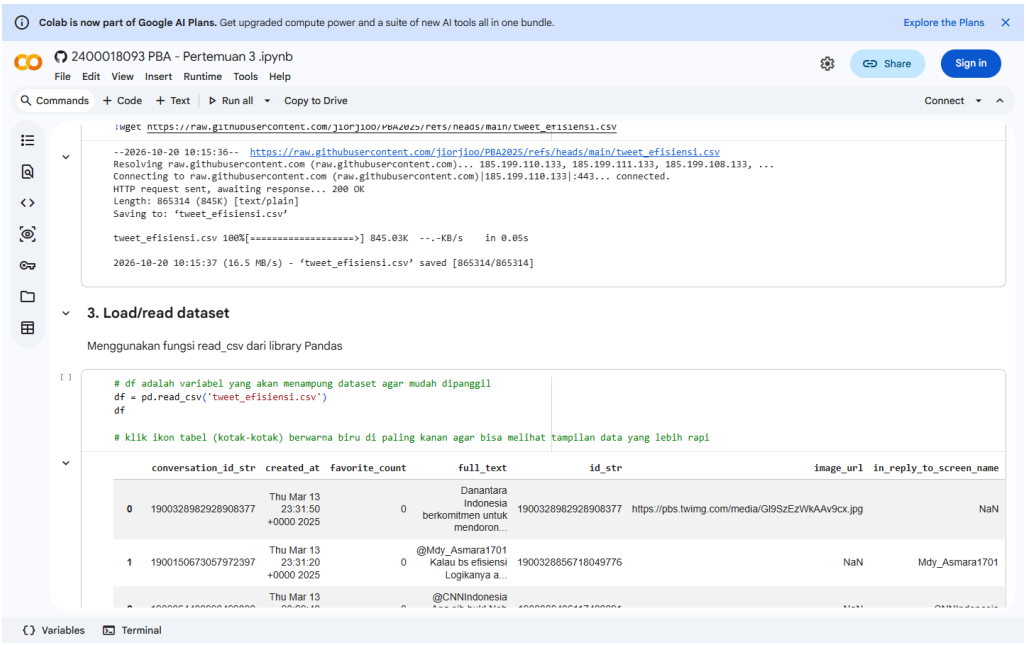
Instalasi dan pemuatan modul Sastrawi.Stemmer.StemmerFactory untuk memproses afiks morfologi kata Bahasa Indonesia.



Gambar 3.2 Tampilan Awal Notebook Praktikum Stemming

3.2 Pemotongan Imbuhan Menggunakan Sastrawi Stemmer

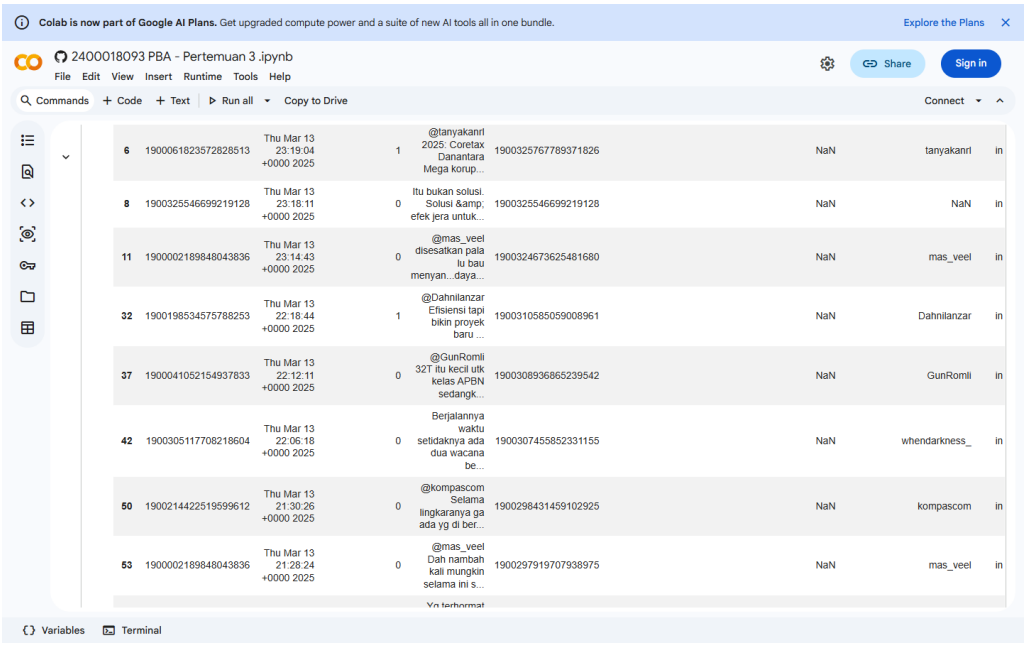
Berbagai kata berimbuhan (awalan, akhiran, sisipan) diuji. Modul Sastrawi berhasil mengembalikan kata ke bentuk lema dasarnya.



Gambar 3.3 Kode Eksekusi Stemming Sastrawi pada Korpus Teks

3.3 Penggunaan Regular Expression (re.sub)

Fungsi regex re.sub() diterapkan untuk menghapus deretan angka, spasi ganda berlebih, dan karakter non-alfanumerik secara efisien.



Gambar 3.4 Hasil Reduksi Kata Dasar dan Pembersihan Regex

Ulasan Praktikum

Stemming bahasa Indonesia memiliki tantangan unik karena adanya aturan peluruhan huruf (seperti meng- + sapu menjadi menyapu). Algoritma Sastrawi mengatasi hal ini dengan pendekatan berbasis aturan morfologi dan pengecekan kamus kata dasar.

Post Test

Latihan post-test diambil langsung dari notebook '2400018093 PBA - Pertemuan 3 .ipynb' menggunakan dataset 'tweet_efisiensi.csv':

1. Pemfilteran Dataset (Rentang Indeks 140-500 dan Kata Kunci 'Rakyat')

Data dari file 'tweet_efisiensi.csv' disaring pada rentang baris indeks 140 hingga 500 (df[140:501]). Dari data hasil seleksi tersebut, dilakukan filtering lebih lanjut untuk mengekstrak hanya tweet yang memuat kata 'rakyat'.

```
df = pd.read_csv('tweet_efisiensi.csv')
df = df[140:501]
df = df[df['full_text'].str.contains('rakyat', case=False,
na=False)]
df.head()
```

Kode 3.1 Filtering Rentang Baris dan Kata Kunci Rakyat

2. Preprocessing dan Stemming Menggunakan Sastrawi

Data dibersihkan melalui fungsi text_preprocessing_process(), lalu diterapkan stemming bahasa Indonesia menggunakan pustaka Sastrawi (text_stemming) pada kolom 'cleaned_text' dan disimpan ke kolom 'stemmed_text'.

```
df['cleaned_text'] =
df['full_text'].apply(text_preprocessing_process)
df['stemmed_text'] = df['cleaned_text'].apply(text_stemming)
df[['full_text', 'cleaned_text', 'stemmed_text']].head()
```

Kode 3.2 Pembersihan Teks dan Stemming Sastrawi

3. Identifikasi 5 Kata Berimbuhan dan Bentuk Dasar Hasil Stemming

Berdasarkan pengujian pada sampel korpus teks hasil filtering, ditemukan lima kata berimbuhan beserta lema bentuk dasarnya:

1. penegak -> tegak (penghapusan awalan 'pe-')
2. mobilnya -> mobil (penghapusan akhiran kepemilikan '-nya')
3. dikejar -> kejar (penghapusan awalan pasif 'di-')
4. dipotong -> potong (penghapusan awalan pasif 'di-')
5. berguna -> guna (penghapusan awalan 'ber-')

4. Tokenisasi Kata dan Tiga Token Paling Dominan

Kolom hasil stemming ('stemmed_text') ditokenisasi menggunakan fungsi tokenize_text(). Perhitungan frekuensi menunjukkan 3 token paling dominan yang sering muncul pada data adalah 'rakyat', 'efisiensi', dan 'pemerintah'.

```
df['tokenized_text'] = df['stemmed_text'].apply(tokenize_text)
cek_freq = df['tokenized_text'].explode().value_counts()
print('Tiga Token Teratas:\n', cek_freq.head(3))
```

Kode 3.3 Tokenisasi dan Identifikasi Token Dominan