Nama: Firzal Akbar Ramadhan
NIM: 2400018093
Tugas Pemrosesan Bahasa Alami
mencari 4 paper tentang BoW, N Gram, TF IDF, dan NER

RESUME DAN ANALISIS KOMPARATIF 4 PAPER PEMROSESAN BAHASA ALAMI (NLP): BAG OF WORDS (BoW), N-GRAM, TF-IDF, DAN NAMED ENTITY RECOGNITION (NER)

Ringkasan Intisari Artikel Ilmiah Bereputasi dan Perbandingan Multidimensi Empat Teknik Representasi Teks

BAB I. PENDAHULUAN

Pemrosesan Bahasa Alami atau Natural Language Processing (NLP) merupakan cabang kecerdasan buatan yang berfokus pada kemampuan komputer dalam memahami, mengolah, dan mengekstrak informasi dari bahasa alami manusia. Teks merupakan data tidak terstruktur yang tidak dapat diproses secara langsung oleh operasi matematis machine learning. Oleh sebab itu, tahapan representasi teks (vektorisasi) menjadi jembatan fundamental untuk mengubah simbol kata menjadi fitur numerik bermakna.

Evolusi Teknik: Dalam perkembangan NLP, terdapat spektrum teknik representasi yang berevolusi dari model leksikal statistik sederhana hingga representasi kontekstual mendalam berbasis deep learning:

- **1. Bag of Words (BoW):** Model frekuensi leksikal diskret tanpa mempertimbangkan urutan kata.
- **2. N-Gram:** Model pemotongan urutan sekuensial karakter atau kata sepanjang n yang mempertahankan struktur lokal.
- **3. TF-IDF:** Model pembobotan statistik yang memperhitungkan frekuensi lokal sekaligus kelangkaan global korpus.
- **4. Named Entity Recognition (NER):** Tugas ekstraksi entitas semantik menggunakan embedding dinamis kontekstual dua arah berbasis arsitektur Transformer (BERT).

Resume ini menyajikan sintesis padat dari empat paper penelitian yang mengimplementasikan masing-masing teknik tersebut pada kasus nyata (ulasan mobile, deteksi plagiarisme, ekstraksi berita, dan rekam medis), diikuti oleh analisis komparatif mendalam mengenai perbedaan konsep, kelebihan, kelemahan, serta kesesuaian penerapannya.

BAB II. RESUME PAPER 1: BAG OF WORDS (BoW / COUNTVECTORIZER)

2.1 Identitas Paper

- **Judul:** Analisis Sentimen Ulasan PeduliLindungi Menggunakan Algoritma Support Vector Machine
- **Penulis:** Andreas Baskoro Wibowo, Moeljono Widjaja, dan Seng Hansun
- **Institusi:** Informatika, Universitas Multimedia Nusantara, Tangerang, Indonesia
- **Publikasi:** JIKO (Jurnal Informatika dan Komputer), Vol. 10, No. 1, Hal. 232–240, Februari 2026. DOI: 10.26798/jiko.v10i1.2327

2.2 Ringkasan Latar Belakang & Masalah

Kewajiban penggunaan aplikasi PeduliLindungi sebagai bukti vaksinasi COVID-19 dan pelacakan kontak di Indonesia menghasilkan ribuan ulasan pengguna di Google Play Store. Ulasan ini memuat evaluasi kepuasan publik yang sangat penting bagi pengembang. Namun, pemilahan manual membutuhkan waktu lama dan rentan bias karena rating bintang pengguna sering kali tidak selaras dengan narasi sentimen yang dituliskan. Penelitian ini bertujuan membangun model klasifikasi sentimen otomatis (positif, netral, negatif) menggunakan algoritma Support Vector Machine (SVM) dengan membandingkan teknik ekstraksi fitur Bag of Words (CountVectorizer) dan TF-IDF.

2.3 Konsep Teknik Bag of Words (CountVectorizer)

Bag of Words (BoW) merepresentasikan teks sebagai kumpulan kata acak tanpa memperhatikan tata bahasa dan urutan kata. Dalam pustaka Scikit-Learn, BoW diimplementasikan melalui algoritma CountVectorizer. Algoritma ini membentuk kamus kata unik dari korpus dan merepresentasikan setiap dokumen sebagai vektor integer count. Setiap elemen vektor menunjukkan frekuensi kemunculan kata pada dokumen. Kata yang muncul berulang kali memperoleh bobot hitungan lebih tinggi, sedangkan kata yang tidak ada diberi nilai nol. Kelemahan bawaannya adalah menghasilkan matriks sparse berdimensi tinggi dan memberikan bobot datar (misal bobot 1) pada semua kata unik tanpa membedakan kata umum vs kata penting.

2.4 Metodologi Penelitian

- **1. Pengumpulan Data:** 1.400 data ulasan Google Play Store (berstrata rating 1 sampai 5) diambil menggunakan pustaka google-play-scraper.
- **2. Validasi Label Manual:** Rating bintang awal divalidasi manual dengan membaca isi narasi ulasan satu per satu untuk memastikan kesesuaian sentimen, menghasilkan 1.385 ulasan valid (549 positif, 550 negatif, 286 netral).
- **3. Preprocessing Teks:** Case folding, pembersihan tanda baca/angka/emoji, stopword removal, stemming algoritma Sastrawi, dan tokenizing.
- **4. Ekstraksi Fitur:** CountVectorizer (Bag of Words) dan TF-IDF.
- **5. Pemodelan Machine Learning:** Support Vector Machine (SVM) linear kernel dengan skema One-vs-Rest (OvR) dan rasio latih:uji 80:20.

2.5 Hasil Eksperimen & Pembahasan

Evaluasi model SVM pada tiga skenario pengujian dirangkum sebagai berikut:

Skenario Pengujian	Akurasi	Precision	Recall	F1-Score
1. TF-IDF Sebelum Validasi Label	0,57 (57%)	0,57	0,59	0,58
2. CountVectorizer (BoW) Setelah Validasi	0,78 (78%)	0,71	0,73	0,71
3. TF-IDF Setelah Validasi Label	0,83 (83%)	0,79	0,81	0,79

Pembahasan: CountVectorizer (BoW) berhasil mencapai akurasi solid sebesar 78%, membuktikan keandalannya sebagai baseline ekstraksi fitur teks yang ringan komputasi. TF-IDF unggul 5% (akurasi 83%) karena menghukum kata yang sering muncul (seperti kata 'update') dan menaikkan bobot kata unik

('harus'). Selain itu, validasi label manual terbukti sangat krusial, menaikkan performa dari 57% ke 83% (lonjakan 26%).

2.6 Kesimpulan Paper 1

Penerapan SVM dengan fitur Bag of Words (CountVectorizer) dan TF-IDF sukses mengklasifikasikan sentimen ulasan PeduliLindungi dengan akurasi 78% - 83%. Validasi manual label data dan pembersihan teks terbukti menjadi faktor penentu utama keberhasilan performa model.

BAB III. RESUME PAPER 2: METODE N-GRAM

3.1 Identitas Paper

- **Judul:** Implementasi Deteksi Plagiarisme Menggunakan Metode N-Gram dan Jaccard Similarity Terhadap Algoritma Winnowing
- **Penulis:** Sunardi, Anton Yudhana, dan Iif Alfiatul Mukaromah
- **Institusi:** Teknik Elektro & Magister Informatika, Universitas Ahmad Dahlan (UAD), Yogyakarta
- **Publikasi:** TRANSMISI, Vol. 20, No. 3, Hal. 101–107, Juli 2018. p-ISSN: 1411-0814, e-ISSN: 2407–6422

3.2 Ringkasan Latar Belakang & Masalah

Plagiarisme karya ilmiah akademik di perguruan tinggi marak terjadi akibat kemudahan praktik copy-paste di internet tanpa sitasi. Deteksi plagiarisme konvensional dengan mencocokkan kata perkata secara utuh sangat boros sumber daya komputasi dan mudah dikelabui modifikasi kalimat. Oleh karena itu, penelitian ini merancang sistem deteksi kesamaan dokumen otomatis menggunakan metode N-Gram karakter, algoritma Winnowing berbasis Rolling Hash untuk membentuk fingerprint dokumen, dan koefisien Jaccard Similarity.

3.3 Konsep Teknik N-Gram

N-Gram adalah teknik pemecahan teks menjadi rangkaian substring sepanjang n secara berkesinambungan dan saling tumpang tindih (overlapping). Pada paper ini, N-Gram diterapkan pada level karakter. Contoh: string 'Magister Teknik Informatika' dengan N=4 menghasilkan potongan gram: [magi, agis, gist, iste, ..., atik, tika]. Keunggulan karakter N-Gram adalah mempertahankan informasi urutan lokal serta kebal terhadap kesalahan ketik (typo), variasi imbuhan morfologi, dan modifikasi spasi.

3.4 Metodologi Penelitian & Perancangan Sistem

- **1. Preprocessing:** Penghapusan spasi/tanda baca (tokenizing) dan konversi ke huruf kecil (case folding) menghasilkan string kontinu.
- **2. Pembentukan N-Gram:** Membentuk potongan string sepanjang n karakter bergeser 1 posisi per langkah.
- **3. Rolling Hash:** Mengonversi setiap gram menjadi nilai numerik hash ASCII secara efisien menggunakan formula rolling hash Rabin-Karp.
- **4. Algoritma Winnowing:** Mengelompokkan nilai hash ke dalam jendela window (W) dan memilih nilai hash terkecil (minimum) di setiap jendela sebagai sidik jari (fingerprint) dokumen.
- **5. Jaccard Similarity:** Menghitung rasio irisan terhadap gabungan himpunan fingerprint kedua dokumen: $Sim(X,Y) = |X \cap Y| / |X \cup Y| * 100\%$.

3.5 Hasil Eksperimen & Pembahasan

Pengujian variasi parameter nilai N (panjang gram) dan W (ukuran window) menghasilkan derajat kemiripan:

No	Kalimat Dokumen Pembanding	N	W	Hasil Similarity
1	Magister Teknik Elektro vs Informatika	3	3	35,71%
2	Magister Teknik Elektro vs Informatika	5	3	41,67%
3	Magister Teknik Elektro vs Informatika	4	5	45,45%
4	Magister Teknik Elektro vs Informatika	4	4	41,67%
5	Magister Teknik Elektro vs Informatika	6	6	18,18%

Pembahasan: Pengujian membuktikan bahwa nilai parameter N dan W berbanding terbalik dengan sensitivitas kecocokan. Nilai N dan W yang kecil menghasilkan potongan pendek yang mudah cocok (kemiripan mencapai 45,45%), sedangkan nilai N=6 dan W=6 menuntut kecocokan frasa yang lebih panjang sehingga kemiripan turun menjadi 18,18%. Pada dokumen sampel yang dijiplak penuh dengan parameter N=3 dan W=5, sistem mendeteksi kesamaan hingga 100%, mengungguli metode K-gram terdahulu (83%).

3.6 Kesimpulan Paper 2

Metode N-Gram yang dipadukan dengan Winnowing dan Jaccard Similarity terbukti sangat efektif dan andal dalam mendeteksi plagiarisme dokumen akademik. Representasi fingerprint berhasil mereduksi ukuran teks secara signifikan tanpa kehilangan informasi struktur kemiripan.

BAB IV. RESUME PAPER 3: METODE TF-IDF

4.1 Identitas Paper

- **Judul:** Keyword Extraction Judul Berita Online Di Indonesia Menggunakan Metode TF-IDF
- **Penulis:** Ibnu Surya Wibowo, Arita Witanti, dan Indah Susilawati
- **Institusi:** Fakultas Teknologi Informasi, Universitas Mercu Buana Yogyakarta
- **Publikasi:** JATISI, Vol. 11, No. 1, Hal. 99–111, Maret 2024. ISSN: 2407-4322, E-ISSN: 2503-2933

4.2 Ringkasan Latar Belakang & Masalah

Tiga portal berita daring terbesar di Indonesia (Kompas.com, Detik.com, Tempo.co) mempublikasikan ratusan ribu artikel setiap tahunnya. Judul berita merefleksikan intisari isu aktual publik. Mengidentifikasi tren dan isu utama dari lautan judul berita membutuhkan teknik Keyword Extraction otomatis yang mampu membedakan kata penting dari kata-kata umum yang sering berulang.

4.3 Konsep Teknik TF-IDF

TF-IDF (Term Frequency - Inverse Document Frequency) adalah algoritma pembobotan statistik yang mengukur tingkat kepentingan kata dalam suatu dokumen relatif terhadap seluruh korpus. Term Frequency mengukur frekuensi kemunculan kata pada dokumen lokal (TF = f(d,t)), sedangkan Inverse

Document Frequency mengukur kelangkaan kata secara global (IDF = log(D / df(t))). Bobot akhir dihitung melalui perkalian W = TF * IDF. Melalui formula ini, kata yang muncul di hampir semua dokumen akan memperoleh penalti bobot mendekati nol, sedangkan kata spesifik isu tertentu memperoleh bobot tinggi.

4.4 Metodologi Penelitian

- **1. Korpus Data:** Web scraping 599.458 judul berita selama satu tahun (Kompas: 366.669, Detik: 123.685, Tempo: 109.104).
- **2. Preprocessing Teks:** Case folding, tokenizing, stopword removal (menghapus kata tugas), dan stemming.
- **3. Pembobotan TF-IDF:** Menggabungkan korpus dan menghitung bobot TF-IDF untuk menentukan Top 30 Keyword.
- **4. Evaluasi Model:** Pengujian daya diskriminasi fitur kata kunci menggunakan klasifikasi sumber berita (split 80:20) dengan metrik Accuracy dan F1-Score.

4.5 Hasil Eksperimen & Pembahasan

Ekstraksi menghasilkan Top 30 kata kunci terpopuler di Indonesia, dengan 10 teratas sebagai berikut:

No	Keyword	Skor TF-IDF	No	Keyword	Skor TF-IDF
1	indonesia	5116	6	jokowi	4207
2	hari	5024	7	tahun	3998
3	cara	4578	8	baru	3998
4	soal	4491	9	kasus	3946
5	polisi	4333	10	rumah	3601

Pembahasan: Pengujian klasifikasi fitur TF-IDF menghasilkan Accuracy sebesar 99,76% dan F1-Score sebesar 99,67%. Analisis per portal menunjukkan kelas Tempo dan Kompas memiliki kinerja sangat tinggi (F1 1.00 dan 0.81), sedangkan kelas Detik menghadapi recall rendah (0,14) karena heterogenitas gaya penulisan judul. Secara keseluruhan, TF-IDF terbukti sangat efektif menonjolkan kata kunci representatif dari big data berita.

4.6 Kesimpulan Paper 3

Metode TF-IDF sukses mengekstrak kata kunci esensial dari hampir 600.000 judul berita online dengan akurasi 99,76%, secara akurat memetakan isu nasional seputar kebijakan pemerintah, hukum, dan ekonomi.

BAB V. RESUME PAPER 4: NAMED ENTITY RECOGNITION (NER)

5.1 Identitas Paper

- **Judul:** Named Entity Recognition for Medical Records of Heart Failure Using a Pre-trained BERT Model

- **Penulis:** Mikael Triartama Manurung, I Gusti Ngurah Lanang Wijayakusuma, dan I Putu Winada Gautama
- **Institusi:** Jurusan Matematika, Universitas Udayana, Bali, Indonesia
- **Publikasi:** Journal of Applied Informatics and Computing (JAIC), Vol. 9, No. 2, Hal. 341–348, April 2025. e-ISSN: 2548-6861

5.2 Ringkasan Latar Belakang & Masalah

Penyakit gagal jantung menyumbang 1,5 juta kasus per tahun di Indonesia. Catatan rekam medis elektronik (RME) di rumah sakit tersimpan dalam bentuk teks naratif bebas yang tidak terstruktur. Ketiadaan struktur data menyulitkan dokter dalam meninjau riwayat pasien secara cepat. Dibutuhkan sistem Named Entity Recognition (NER) otomatis untuk mengklasifikasikan informasi klinis ke dalam kategori terstandarisasi.

5.3 Konsep Teknik NER & Arsitektur Pre-trained BERT

Named Entity Recognition (NER) adalah tugas NLP untuk mengidentifikasi dan mengelompokkan token teks ke dalam kategori entitas semantik tertentu. Paper ini memanfaatkan model pre-trained BERT (Bidirectional Encoder Representations from Transformers). BERT menggunakan arsitektur Transformer Encoder dengan mekanisme Multi-Head Self-Attention yang membaca konteks kalimat secara dua arah (bidirectional). Berbeda dari embedding statis, BERT menghasilkan embedding dinamis di mana representasi vektor kata berubah mengikuti konteks kalimat klinis di sekitarnya.

5.4 Metodologi Penelitian

- **1. Dataset Klinis:** 1.000 rekam medis pasien gagal jantung RSUP Prof. Ngoerah dibersihkan menjadi 724 token kalimat medis.
- **2. Skema 4 Entitas:** OBJ (Data Objektif/Lab), SUBJ (Keluhan Pasien), DIAG (Kode & Diagnosa), dan RESEP (Resep Obat).
- **3. Pembagian Data:** 463 data latih, 116 data uji, dan 145 data validasi (tokenisasi bert-base-cased).
- **4. Fine-Tuning BERT:** Fine-tuning BertForSequenceClassification dengan batch size 8, learning rate 2e-5, 5 epoch, dan optimizer AdamW.
- **5. Pipeline Inferensi:** Menerima narasi klinis bebas dan menghasilkan ringkasan terstruktur 4 kategori secara otomatis.

5.5 Hasil Eksperimen & Pembahasan

Pelatihan 5 epoch menunjukkan konvergensi sehat: training loss turun dari 0,0998 ke 0,0028 dan validation loss turun dari 0,0299 ke 0,0017. Evaluasi pada data uji menghasilkan akurasi keseluruhan sebesar 84,82% (Macro F1: 0,84). Kinerja per kategori entitas dirinci pada tabel berikut:

Kategori Entitas Medis	Precision	Recall	F1-Score
RESEP (Resep Obat)	1,00 (100%)	1,00 (100%)	1,00 (100%)
DIAG (Diagnosa)	0,97 (97%)	0,89 (89%)	0,93 (93%)
OBJ (Data Objektif)	0,69 (69%)	1,00 (100%)	0,81 (81%)
SUBJ (Data Subjektif)	0,82 (82%)	0,50 (50%)	0,62 (62%)

Rata-Rata Makro (Macro Avg)	0,87	0,85	0,84 (84%)

Pembahasan: Kategori RESEP mencapai skor sempurna 1.00 karena terminologi obat sangat spesifik. DIAG mencapai F1 0.93 berkat pola kode ICD yang jelas. Tantangan utama terjadi pada SUBJ (F1 0.62) di mana 17 sampel keliru diprediksi sebagai OBJ akibat variasi bahasa narasi keluhan pasien yang sering bercampur dengan catatan objektif perawat. Capaian ini sangat kompetitif dibanding model state-of-the-art seperti BiLSTM-CRF (F1 79,27%) dan GPT (Presisi 93%).

5.6 Kesimpulan Paper 4

Fine-tuning model pre-trained BERT berhasil mengekstrak entitas rekam medis gagal jantung berbahasa Indonesia dengan akurasi 84,82%, membuktikan superioritas arsitektur Transformer dalam menangkap konteks semantik bahasa klinis.

BAB VI. PERBANDINGAN DAN ANALISIS PERBEDAAN KEEMPAT TEKNIK NLP

6.1 Matriks Komparasi Teoretis Empat Teknik

Tabel berikut menyajikan perbandingan karakteristik teknis fundamental dari keempat teknik NLP:

Karakteristik	Bag of Words (BoW)	N-Gram	TF-IDF	Named Entity Recognition (BERT)
Prinsip Dasar	Frekuensi kemunculan token kata independen.	Irisan substring sekuensial sepanjang n.	Bobot statistik frekuensi lokal vs keunikan global.	Klasifikasi entitas berbasis pemahaman konteks semantik.
Representasi Vektor	Vektor sparse integer (|V| kosakata).	Himpunan n-tuple atau integer hash.	Vektor sparse nilai desimal float.	Matriks dense embedding dinamis (768 dimensi).
Penanganan Urutan Kata	Nol (diabaikan sepenuhnya).	Lokal (sepanjang n token/karakter).	Nol (diabaikan sepenuhnya).	Penuh & dua arah (Positional Encoding + Self-Attention).
Sensitivitas Konteks	Rendah (kata polisemi identik).	Sensitif pada pola ejaan/frasa lokal.	Peka dokumen, buta sintaksis kalimat.	Sangat tinggi (makna dinamis mengikuti kalimat).
Kompleksitas Komputasi	Sangat rendah O(N), ringan di CPU.	Rendah (efisien via Rolling Hash).	Rendah ke moderat, skalabel.	Sangat tinggi, membutuhkan akselerasi GPU/TPU.
Ketahanan Typo	Rentan (typo dianggap token baru).	Sangat tangguh pada level karakter.	Rentan pada kesalahan ejaan.	Tangguh melalui WordPiece sub-word tokenization.

6.2 Matriks Komparasi Empat Studi Kasus Paper

Tabel berikut merangkum perbandingan empiris dari implementasi keempat paper penelitian:

Dimensi Studi Kasus	Paper 1 (BoW)	Paper 2 (N-Gram)	Paper 3 (TF-IDF)	Paper 4 (NER BERT)
Domain & Tugas	Sentimen ulasan PeduliLindungi (Klasifikasi SVM).	Deteksi plagiarisme karya ilmiah (Fingerprinting).	Ekstraksi kata kunci berita online (Keyword Ranking).	Ekstraksi informasi rekam medis gagal jantung (NER).
Ukuran Dataset	1.400 ulasan Play Store (1.385 valid).	Dokumen teks akademik & sample uji.	599.458 judul berita (Kompas, Detik, Tempo).	1.000 RME RS Prof. Ngoerah (724 token kalimat).
Preprocessing Kunci	Pembersihan simbol, Sastrawi, validasi manual.	Case folding, penghapusan spasi & tanda baca.	Case folding, tokenizing, stopword, stemming.	Deduplikasi No. RM, tokenisasi bert-base-cased.
Algoritma / Pipeline	CountVectorizer + Linear SVM (OvR).	Character N-Gram + Rolling Hash + Winnowing + Jaccard.	Matriks TF-IDF + Scikit-Learn split 80:20.	Fine-Tuned BertForSequenceClassification (AdamW).
Hasil & Capaian Akhir	Akurasi: 78% (BoW) & 83% (TF-IDF).	Similarity: 18% - 45% (hingga 100% pada uji identik).	Akurasi: 99,76%, F1: 99,67% (Top 1: 'indonesia').	Akurasi: 84,82%, Macro F1: 0,84 (Resep F1 1.00).

6.3 Analisis Perbedaan Filosofi & Konsep Representasi

Filosofi Representasi: Perbedaan paling mendasar terletak pada cara memodelkan bahasa:

- **1. Bag of Words:** Memandang teks secara atomik dan independen. Keberadaan kata dihitung tanpa mempedulikan posisi sintaksis, menghasilkan representasi ortogonal yang sederhana namun kaku.
- **2. N-Gram:** Memandang teks sebagai aliran sekuensial. Keunikan bahasa diyakini tersimpan dalam fragmen urutan lokal, sehingga pencocokan substring bergeser sangat efektif menangkap kemiripan bentuk teks.
- **3. TF-IDF:** Memadukan statistik kemunculan dengan teori informasi. TF-IDF mengakui bahwa kata langka memiliki entropi informasi lebih tinggi dibanding kata umum, memungkinkan eliminasi otomatis terhadap stopword.
- **4. Named Entity Recognition (BERT):** Mewakili paradigma representasi kontinu probabilistik modern. BERT menempatkan kata ke dalam ruang vektor padat di mana maknanya ditentukan secara dinamis oleh seluruh konteks kalimat sekitarnya.

6.4 Analisis Kelebihan dan Kelemahan Komparatif

- **1. Bag of Words:** Kelebihan: Sangat cepat, hemat komputasi, mudah diinterpretasikan. Kelemahan: Curse of dimensionality, sparsity tinggi, mengabaikan urutan dan konteks negasi.
- **2. N-Gram:** Kelebihan: Sangat tangguh terhadap typo dan variasi ejaan, menangkap struktur lokal. Kelemahan: Kombinasi n-gram meledak saat nilai n besar, gagal menangkap dependensi jarak jauh.
- **3. TF-IDF:** Kelebihan: Otomatis menekan kata umum, menonjolkan kata kunci diskriminatif, skalabel untuk korpus jutaan teks. Kelemahan: Tetap mengabaikan tata bahasa dan hubungan semantik antar kata.

- **4. NER (BERT):** Kelebihan: Akurasi semantik tingkat tinggi, memahami nuansa kontekstual dan kalimat kompleks. Kelemahan: Biaya komputasi tinggi (butuh GPU), inferensi lebih lambat, memerlukan anotasi data latih berlabel yang mahal.

6.5 Panduan Kesesuaian Penggunaan (Use Cases)

- • **BoW:** Cocok untuk baseline klasifikasi teks cepat, analisis sentimen sederhana, dan lingkungan dengan komputasi terbatas.
- • **N-Gram:** Pilihan utama untuk sistem deteksi plagiarisme, pencocokan string bioinformatika (DNA), dan koreksi ejaan otomatis.
- • **TF-IDF:** Sangat tepat untuk mesin pencari (Information Retrieval), peringkasan dokumen ekstraktif, dan pemetaan topik tren dari korpus berita besar.
- • **NER (BERT):** Wajib digunakan pada domain kritis berisiko tinggi (high-stakes) seperti rekam medis kesehatan, analisis kontrak hukum, dan sistem ekstraksi informasi berbasis AI cerdas.

BAB VII. KESIMPULAN UMUM

Kajian komparatif terhadap empat artikel ilmiah bereputasi ini menegaskan bahwa tidak ada satu teknik representasi teks yang unggul mutlak dalam segala situasi. Pemilihan teknik NLP selalu melibatkan trade-off antara akurasi semantik dan efisiensi komputasi.

Model leksikal seperti BoW dan TF-IDF tetap sangat relevan untuk ekstraksi cepat pada dataset berskala raksasa karena keunggulannya dalam efisiensi memori dan kecepatan pelatihan. N-Gram menyediakan solusi kokoh untuk mendeteksi kesamaan struktur teks pada kasus plagiarisme. Sementara itu, model deep learning berbasis Transformer (BERT) pada tugas Named Entity Recognition menetapkan standar tertinggi dalam pemahaman konteks semantik mendalam pada data tidak terstruktur yang sensitif seperti rekam medis klinis.

DAFTAR PUSTAKA

[1] A. B. Wibowo, M. Widjaja, dan S. Hansun, 'Analisis Sentimen Ulasan PeduliLindungi Menggunakan Algoritma Support Vector Machine,' Jurnal Informatika dan Komputer (JIKO), vol. 10, no. 1, hal. 232–240, Feb. 2026, doi: 10.26798/jiko.v10i1.2327.

[2] Sunardi, A. Yudhana, dan I. A. Mukaromah, 'Implementasi Deteksi Plagiarisme Menggunakan Metode N-Gram dan Jaccard Similarity Terhadap Algoritma Winnowing,' TRANSMISI: Jurnal Ilmiah Teknik Elektro, vol. 20, no. 3, hal. 101–107, Jul. 2018, p-ISSN: 1411-0814, e-ISSN: 2407–6422.

[3] I. S. Wibowo, A. Witanti, dan I. Susilawati, 'Keyword Extraction Judul Berita Online Di Indonesia Menggunakan Metode TF-IDF,' Jurnal Teknik Informatika dan Sistem Informasi (JATISI), vol. 11, no. 1, hal. 99–111, Mar. 2024, ISSN: 2407-4322, E-ISSN: 2503-2933.

[4] M. T. Manurung, I. G. N. L. Wijayakusuma, dan I. P. W. Gautama, 'Named Entity Recognition for Medical Records of Heart Failure Using a Pre-trained BERT Model,' Journal of Applied Informatics and Computing (JAIC), vol. 9, no. 2, hal. 341–348, Apr. 2025, e-ISSN: 2548-6861.